論　文

# 学習オートマトンによるマルチカーエレベータ制御

学生員　白石　和章*　正　員　濱上　知樹**
正　員　平田　廣則*

## Multi Car Elevator Control by using Learning Automaton

Kazuaki Shiraishi*, Student Member, Tomoki Hamagami**, Member, Hironori Hirata*, Member

We study an adaptive control technique for multi car elevators (MCEs) by adopting learning automatons (*LA*s.) The MCE is a high performance and a near-future elevator system with multi shafts and multi cars. A strong point of the system is that realizing a large carrying capacity in small shaft area. However, since the operation is too complicated, realizing an efficient MCE control is difficult for top-down approaches. For example, "bunching up together" is one of the typical phenomenon in a simple traffic environment like the MCE. Furthermore, an adapting to varying environment in configuration requirement is a serious issue in a real elevator service. In order to resolve these issues, having an autonomous behavior is required to the control system of each car in MCE system, so that the learning automaton, as the solutions for this requirement, is supposed to be appropriate for the simple traffic control. First, we assign a stochastic automaton (*SA*) to each car control system. Then, each *SA* varies its stochastic behavior distributions for adapting to environment in which its policy is evaluated with each passenger waiting times. That is *LA* which learns the environment autonomously. Using the *LA* based control technique, the MCE operation efficiency is evaluated through simulation experiments. Results show the technique enables reducing waiting times efficiently, and we confirm the system can adapt to the dynamic environment.

**キーワード：**学習オートマトン，マルチカーエレベータ
**Keywords:** learning automaton, multi car elevator

## 1. はじめに

高度交通システムにおける制御目標は，人や物資を円滑かつ効率よく輸送することである。エレベータシステムもまた，乗客を待たせることなく速やかに移動させることが要求される単純な交通システムの一つである。効率のよい輸送を実現するために，これまでにも様々な制御手法が研究・応用されてきた[(1)~(4)]。

一方，近年の高層建築物の増加に伴い，エレベータのシャフト占有面積が増加する問題が生じている。この問題に対し，従来，スカイロビー方式等によるフロア面積の有効利用が図られてきたが，限られたシャフト占有面積のエレベータで，効率的な輸送を実現する方法は未だ実現されていない。

このようなエレベータシステムの問題を解決する技術として，近年，注目されているのが，リニアモータ技術を用いたマルチカーエレベータ（MCE：Multi Car Elevator）である。MCE は，ロープを牽引する施設が必要ない，シャフト間の横方向移動が可能である等の特長を持つ，単一のシャフト内で複数のかごを運用することが可能なエレベータであることから，現在，実用化に向けた研究が進められている[(5) (6)]。

MCE 制御は，かご同士でシャフト空間を共有できるため，限られたシャフト面積でも，かごの移動自由度が高くなる。一方で，従来の方法と比較して，ダンゴ状運転が発生しやすくなり，輸送の効率が落ちる点が問題となる。これを防ぐために，より複雑な交通システムの制御が必要となる。また，運用変更や障害発生により，各かごの移動範囲（ゾーン）の変化やゾーン間のかごの移動が発生する場合がある。このような場合，従来手法と同様のトップダウンな集中制御を用いていると，その度に全ての運行スケジュール等を再設定する必要が生じる。

このような，トップダウン制御法の欠点を補うためには，システムの各要素が自律しながら分散制御を行うボトムアッ

* 千葉大学大学院自然科学研究科
〒263-8522　千葉市稲毛区弥生町 1-33
Graduate School of Science and Technology, Chiba University
1-33, Yayoi-cho, Inage-ku, Chiba 263-8522
** 横浜国立大学大学院工学研究院
〒240-8501　横浜市保土ヶ谷区常盤台 79-5
Graduate School of Engineering, Yokohama National University
79-5, Tokiwadai, Hodogaya-ku, Yokohama 240-8501

プ的手法が有効である。そのような手法の中でも，筆者らがITS などにおいて検討を進めてきた学習オートマトン（*LA*：Learning Automaton）は，環境からの強化信号を用いて，環境に適応した戦略を自律的に獲得する機構を有し，さらに，ノイズに強く収束性が保証されていることから，MCE の自律分散制御に適した手法であるといえる。すなわち，MCE システムの状態に応じて，各かごが自律的に動作を決定する学習機構を持たせることで，環境に適応した柔軟な運用が期待できる。ボトムアップ的手法を従来のエレベータ群管理に対して応用した研究として，文献(7) 等がある

以上のことを背景として，本研究では，ボトムアップ的手法に属する，学習オートマトンを用いた MCE 制御をシミュレーション上にて実現，提案し，その動作特性を検証することを目的とする。まず，MCE 制御の課題として，ダンゴ状運転と，環境変化への対応を取り上げる。次に，この課題を解決するための学習オートマトンの応用について述べる。そして，計算機シミュレーション実験により，学習オートマトンを用いた MCE 制御を行い，その動作特性について考察する。

## 2. MCE 制御問題

本論文において想定する MCE の構造および用語を図 1 に示す。ここで，「かご（Cars）」は利用者が乗込み移動する箱を指す。「シャフト（Shafts）」は，かごを上下に移動させる機構をもつ中空の柱を指す。「ユニット（Unit）」は，複数のシャフトにより構成されるハードウェア的に独立なエレベータシステムを指す。「ゾーン（Zones）」は，仮想的に設けたかごの移動制約範囲を指す。

また，本論文において想定する MCE は，上昇専用シャフト・下降専用シャフトの 2 つを 1 ユニットとし，かごがゾーン内を循環する運行方式をとる。以上のような構造をとることにより，従来の複数シャフトを候補としてサービスを行う群管理に比較して，少ないシャフトで多くのかごを運用することが可能になり，シャフト占有床面積の問題を大きく改善できる可能性がある。また，上昇専用シャフト・下降専用シャフトから構成される構造により，かごが同一シャフト内を対向する動作をしないため，安全性も高まると考えられる。しかし，従来のエレベータシステムと大きく異なる運用形態であるため従来の群管理問題とは異なる問題が生じる。

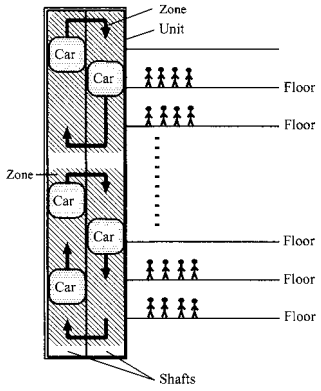


図 1　MCE システム

Fig. 1.　An MCE system.

本論文では，先に述べた循環運行を行う MCE 制御における 2 つの問題を扱う。1 つはダンゴ状運転の問題であり，もう 1 つは環境の変化に対する再設定の問題である。

ダンゴ状運転の問題　　ダンゴ状運転とは，複数のかごが近接した状態で運転される状態である。環状線の鉄道運行では，ダンゴ状態の発生により，全体の運行スケジュールが大きく乱れ，大局的な輸送効率が大幅に落ちるという問題が生じることが知られている[8]。また，MCE の効率的な運転を目指した研究として，鉄道の運行スケジュール決定方法と共通点の多い手法[5]が提案されているが，エレベータシステムにおいてもダンゴ状運転に陥ると，利用者の待ち時間が著しく増加することが予想される。さらに，各かごの停止位置を予測できない，各かごの停止時間のばらつきが大きい等，MCE 固有の条件が重なることで，予め決定された運行スケジュールと規則に従う運行では，ダンゴ状運転が生じやすくなることが予想される。この問題を回避するためには，運行スケジュール等の運行戦略を，各かご毎に動的に変更する機構が必要になる。

環境の変化に対する再設定の問題　　運用の変更や障害時などでは，ゾーンごとに運行スケジュールを設定できることが望ましい。例えば，他のゾーンからかごが流入，・流出するケース，ゾーン自体を変化させるケース等が考えられる。このような変更の場合，トップダウン的手法を用いて運行スケジュールを決定すると，全体の運行スケジュールを再設定しなくてはならない問題があった。この問題を回避するためには，運用環境の変化に応じて，各要素がボトムアップ的に適応し，全体として望ましい運用が実現される必要がある。

## 3. 学習オートマトン（*LA*）

**〈3･1〉 MCE 制御問題への *LA* の適用**　　*LA* は，未知環境（*RE*：Random Environment）と確率オートマトン（*SA*：Stochastic Automaton）により定義される学習機械の一種である。*RE* から得られる報酬を用いて自律的に環境に適応した戦略を獲得し，適切な行動を選択できるという特徴を持つ。また，ノイズに強く収束性が保証されている等の利点もある[9][10]。ここで戦略とは，*SA* が持つ行動の選択確率分布である。

また，近年 *LA* とゲーム理論を結びつける提案がなされ，多数個体同士の協調による，自律分散処理システムへの応用が期待されている。筆者らの一人は，*N* 人によるプレイヤーからなるゲームにおいて，各プレイヤーに相当する *SA* が *RE* 中において，より多くの報酬を得るための戦略を自律的に決定する機構を提案した[11]。この技術を一部利用した具体的応用として筆者らは，*LA* を ITS の自律走行機構に応用し，走行環境の変化に応じて動的に戦略を変える方

法を提案している[12]。

本研究では，この *LA* を，さらに MCE 制御における知的コントローラとして応用する手法について検討する。本手法では，MCE の各かごは *SA* を持ち，MCE 全体の輸送効率を反映した強化信号に基づいて戦略を更新する。つまり，*N* 個のかごが *N* 人のプレイヤーに相当するゲーム的環境において，MCE 全体の輸送効率を高める戦略をボトムアップに決定する。

本研究において用いる *LA* を図 2 に示す。*LA* は，*RE* と *i* 個の *SA* から構成される。*RE* は未知環境，$SA^i$ は，*i* 番目の確率オートマトンである。図中 $y^i$ は，$SA^i$ の行動，*r* は *RE* からの強化信号（$0.0 \le r \le 1.0$）である。

以下に，*LA* による MCE 制御の手順を示す。

（1） 各かごは，対応する *SA* が持つ行動選択確率分布（戦略）に従い，自らの行動を決定する。

（2） 決定された行動を，一定時間持続する。

（3） 一定時間経過後，利用者の平均かご待ち時間を評価関数によって評価し，その結果を強化信号として各かごの *SA* に渡す。

（4） *SA* は，受け取った強化信号を元に行動選択確率分布の更新を行う。すなわち，直近の行動選択確率について，強化信号に応じた当該確率の上げ・下げを行い，戦略を更新する。

（5） 手順（1）へ戻る。

**〈3･2〉 行　動**　行動出力数を多く設定することにより，様々な環境へ適応できる可能性を高めることが期待できる。しかし，行動出力数を大きく設定すると，行動選択確率の収束に時間がかかる問題が予備実験において確認された。また，本論文における目的は，提案手法の動作特性を検証することであるため，本論文における計算機実験は，動作特性検証に必要な最小限の行動出力数で行う。行動出力数は，予備実験により試行錯誤的に求めた。

各かごは，それぞれ一つの *SA* と対応づけられることにより，独立した行動を選択する。各 *SA* は，当該かごの前後にあるかごとの距離（かご間距離）に応じた後述する 3 つの行動出力が可能な混合確率分布を持つものとする。

**行動 1**　かご間距離を無視する。

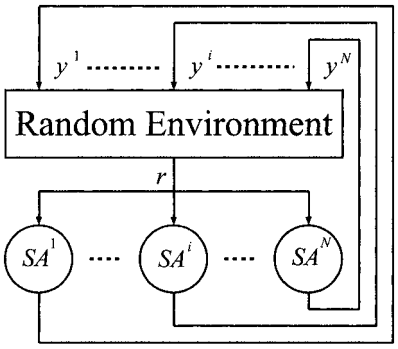


図 2　*LA*

Fig. 2.　An example of *LA*.

**行動 2**　かご間距離が閾値 $th_1$ 以下になると停止する。

**行動 3**　かご間距離が閾値 $th_2$ 以下になると停止する。ただし，$th_1 < th_2$ である。

**〈3･3〉 行動選択確率分布の更新法**　本研究では，より速い収束性能を得るために，前述の *SA* の学習機構に，過去に得られた強化信号の情報を用いる。すなわち，各 *SA* が過去に得た強化信号から重要な行動を推測し，その行動の選択確率をより早く高めるための重み付けを行う。このように学習主体者が過去の強化信号（報酬）に基づいて戦略を決定するゲームのモデルは，現在研究が進められており[13]，*LA* においても有効であると考えられる。例えば，多数のプレイヤーによるゲームにおいても短期的な他プレイヤーの戦略変化に大きく影響されることなく，長期的に見ればより適切な行動を獲得できると考えられる。

本手法を用いた *LA* の詳細を，付録に示す。

**〈3･4〉 強化信号**　強化信号は，ある一定期間における，利用者の平均待ち時間をもとに算出される。ある一定期間とは，後述の行動維持期間（*L*）である。

ある戦略に基づき選択された行動は，一定時間連続して行われる。この期間を行動維持期間（*L*）と呼ぶ。

戦略は，行動維持期間毎に更新され，その都度新たな行動が生成される。ここで，選択された行動の良し悪しを正しく評価するために，行動維持期間すべてを評価対象としない。すなわち，行動維持期間内で待ちが発生し，行動維持期間の後半 $\alpha L (0 < \alpha < 1)$ で待ちが解消された利用者の待ち時間のみで評価を行う。これは，前行動維持期間中の行動が，現在の行動維持期間に及ぼす影響を避けるためである。(1) 式に評価関数を示す。本手法では，評価関数の出力がそのまま強化信号となる。行動維持期間（*L*）に関して図 3 に示す。

なお，現在のエレベータシステムにおいて，利用者の正確な待ち時間を算出する技術は，まだ実用化されてはいない。しかし，各フロアにカメラを設置，画像処理を行うことにより，待ち時間を算出する技術が確立することは将来的に十分に考えられる。現在，画像処理による人数計測システムは，ハードウェアによる実用化段階にはいっており，また，画像処理による人間の行動パターンの認識技術[14]等に関する研究も進められている。本論文では，将来的に実用的精度で利用者の待ち時間を予測することが可能になるとの仮定のもとに，利用者の待ち時間を算出可能であるとして計算機実験を行う。

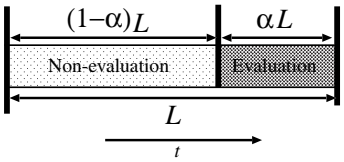


図 3　評価対象期間

Fig. 3.　An evaluation period.

$$r = \frac{w_{\mathrm{floor}}}{\alpha L} \quad \cdots\cdots (1)$$

ここで，$w_{\mathrm{floor}}$ は上記期間内に発生した利用者平均待ち時間である。$\alpha L$ で正規化することにより，強化信号を $0.0 \leq r \leq 1.0$ としている。

## 4. 計算機実験

*LA* を用いた MCE 制御の有効性を，計算機シミュレーションにて評価する。

**〈4•1〉 MCE シミュレータ**　計算機実験に用いる MCE シミュレータの概要を示す（図 4）。MCE シミュレータはクライアント・サーバ方式のシミュレータであり，各かごの制御は一対一に対応付けられた各クライアントによって行われる。*LA* はクライアント側に実装される。

**〈4•1•1〉 MCE シミュレータサーバ**　MCE シミュレータサーバでは，各階毎にエレベータ利用者の発生頻度を自由に設定できる。ただし，簡単のため以下のような制約を設ける。

**1)** 利用者は行き先階に向かう方向へ移動するかごに，フロアでかご待ちを開始した順にかごに乗り込む。ただし，かごの最大搭乗員数を超える場合には，かごに乗り込まない。

**2)** 行き先階に到着したかご内利用者は，必ずかごからフロアへと移動する。

**〈4•1•2〉 MCE シミュレータクライアント**　サーバに接続される各クライアントは，各かごにそれぞれ対応している。各クライアントはサーバから取得した環境情報に基づき内部の *SA* からの出力に応じて行動を決定し，サーバに行動を伝える。伝えられた行動に応じて MCE ユニット内のかごは制御される。これらの処理はそれぞれ独立して実行される。ただし，簡単のため各クライアントの行動に以下のような制約を設ける。

**1)** 各かごは，かご内に利用者がいる場合，利用者の行き先階を通りすぎることはできない。

**2)** 各かごが，かご内利用者の行き先階へ到着した場合，かご内における全ての行き先階到着利用者がフロアに移動するまで停止する。

**3)** 各かごは，一度フロアにてドアを開けると，最大搭乗員数を超えない限り利用者の搭乗を妨げない。

**〈4•2〉 計算機実験 I**　*LA* を用いた MCE 制御法の有効性について，MCE シミュレータを用いた実験を行う。

**〈4•2•1〉 実験条件**　実験に用いたゾーン構成を図 5 に示す。ゾーンは 2 つのシャフトから成り，各シャフトは上昇専用シャフトと下降専用シャフトに分けられているものとする。また，横方向の移動はゾーン内最下階およびゾーン内最上階で一方向にのみ可能であるとする。さらに，各階における利用者の発生率は各階ともに均等とする。計算機実験 I におけるパラメータおよび条件設定を表 1 に示す。利用者はポワソン到着に基づき，各フロア均等に発生するものとする。平均到着率は，1.0 [人/min] とする。

**〈4•2•2〉 結果および考察**　各かごに対応した *SA* の行動選択確率の変化を図 6 から図 10 に示す。各 *SA* とも行動 2 の選択確率が上昇していることがわかる。行動 2 は，フロアでかご待ちをしている利用者の元へ速やかに到着するよりも設定されたかご間距離を空けることを優先する戦略である。

本実験のように各階での利用者発生率が均等である場合，「各かごが距離を均等に保ちながら行動する」ことが，利用者の平均待ち時間を最小にする最適解であることが，待ち

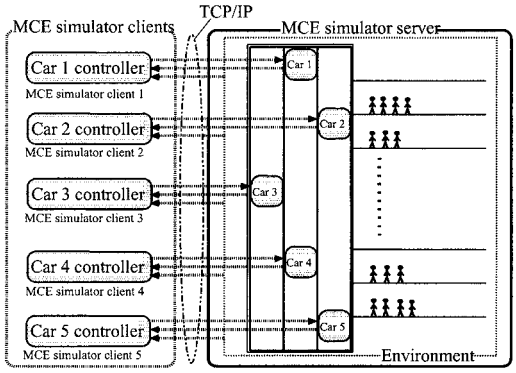


図 4　MCE シミュレータの構成

Fig. 4.　MCE simulator clients and a MCE simulator server.

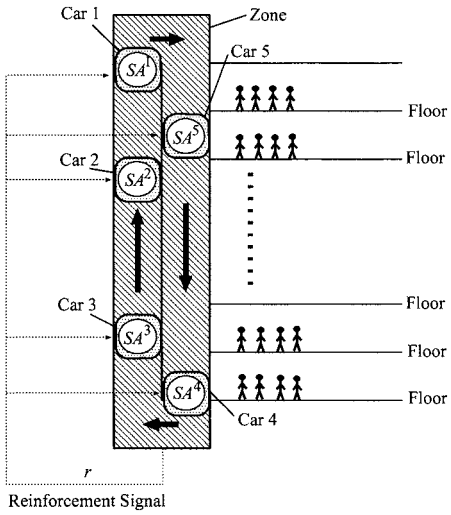


図 5　計算機実験 I の実験環境

Fig. 5.　An experimental environment I.

表 1　計算機実験 I 実験条件

Table 1.　The parameter list for experimentI.

| | |
|---|---|
| Number of floor | 20 |
| Number of car | 5 |
| $th_1$ | 8[floor height] |
| $th_2$ | 16[floor height] |
| Parameter:$L$ | 2400[s] |
| $\alpha$ | 0.25 |
| *LA* Parameter：$\theta$ | 0.01 |
| *LA* Parameter：$\eta$ | 0.5 |

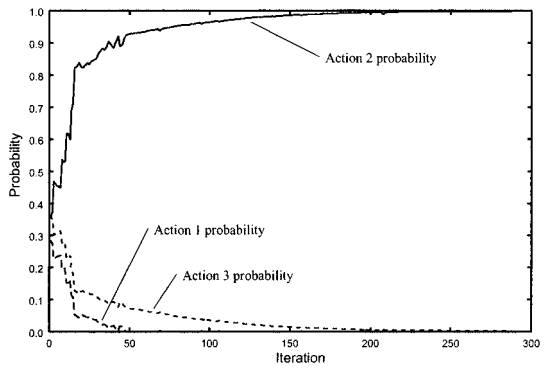


図 6　実験 I : $SA^1$ の行動選択確率の変化
Fig. 6.　Experiment I : The action probability of $SA^1$.

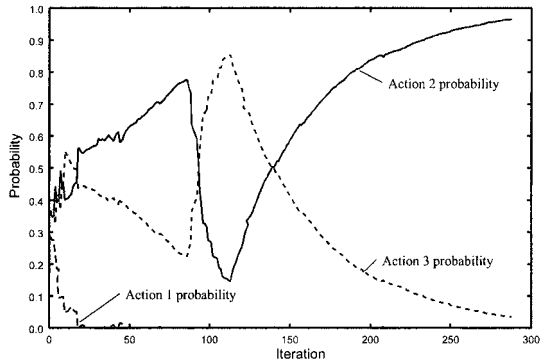


図 7　実験 I：$SA^2$ の行動選択確率の変化
Fig. 7.　Experiment I : The action probability of $SA^2$.

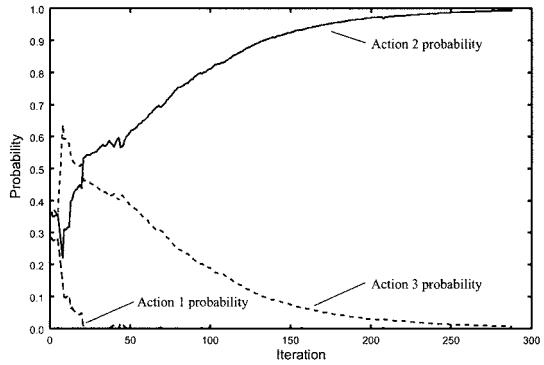


図 8　実験 I：$SA^3$ の行動選択確率の変化
Fig. 8.　Experiment I : The action probability of $SA^3$.

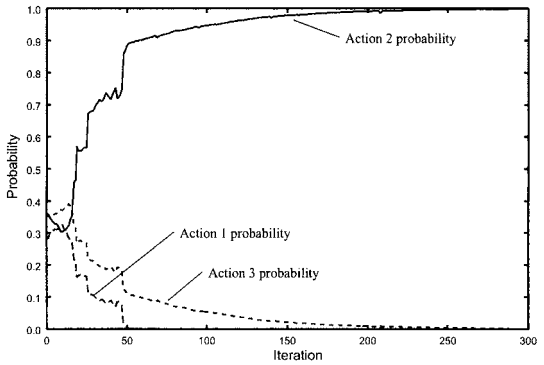


図 9　実験 I : $SA^4$ の行動選択確率の変化
Fig. 9.　Experiment I : The action probability of $SA^4$.

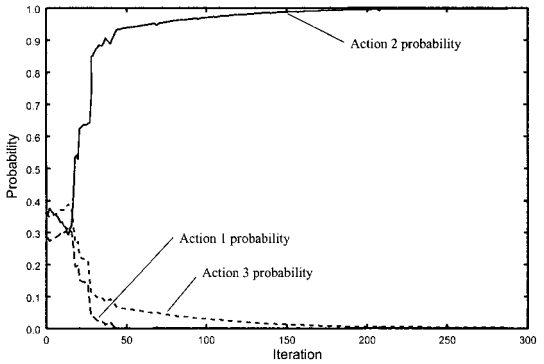


図 10　実験 I：$SA^5$ の行動選択確率の変化
Fig. 10.　Experiment I : The action probability of $SA^5$.

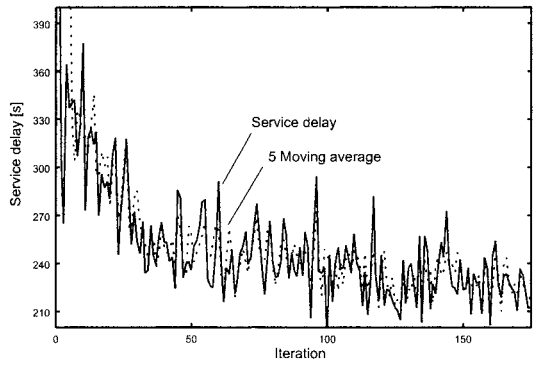


図 11　実験 I : 平均待ち時間の変化
Fig. 11.　Experiment I : The service delay.

行列モデルを用いた理論的解析からわかっている[8]。本実験の結果は，最終的に全ての *SA* において，行動 2 の選択確率がほぼ 1.0 に収束していることから，理論値通りの行動が得られたといえる。

一方，$SA^2$，$SA^3$ は，他の *SA* に比較して行動 2 の行動選択確率へ収束するまでに時間がかかっている。これは，全ての *SA* が最適な行動を選択するまでの過渡期において，$SA^2$，$SA^3$ と他 *SA* の間に役割分担が生じたためと考えられる。上述の振る舞いは，他 *SA* が最もダンゴ状運転を生じやすい行動 1 を選択する可能性が残る 25 から 50 回目の行動選択時付近までに顕著である。すなわち，$SA^2$，$SA^3$ は他 *SA* が行動 1 を選択する可能性が残る期間に，ダンゴ状運転による待ち時間増加を抑えるため，行動 2 と行動 3 の混合戦略をとっていると考えられる。これは，ダンゴ状運転によって大きくなった，かご間の隙間中間付近に $SA^2$，$SA^3$ が位置することで，利用者の待ち時間増加を抑えていることを意味している。

また，後述される図 11 において，利用者の平均待ち時間が 50 回目の行動選択時まで，順調に減少していることも，上述の振る舞いを裏付けている。50 回目の行動選択時付近以降では，全ての *SA* で行動 1 を選択する可能性はほとんどなくなり，$SA^2$，$SA^3$ 以外の *SA* は速やかに行動 2 に収束

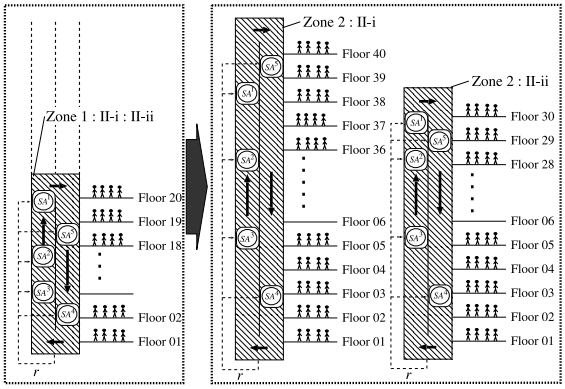


図 12　計算機実験 II の実験環境

Fig. 12.　An experimental environment II.

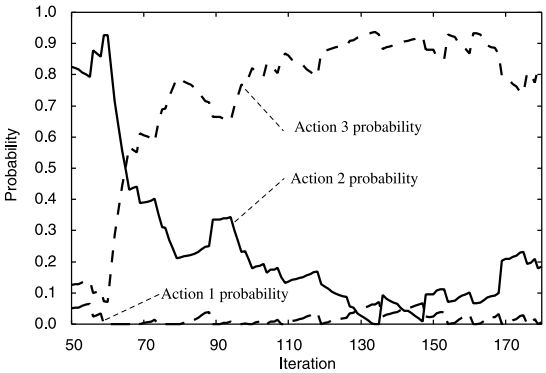


図 13　実験 II-i：*SA* の行動選択確率の変化

Fig. 13.　Experiment II-i: The action probability of an *SA*.

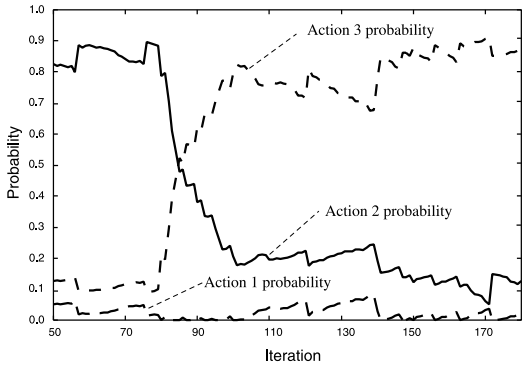


図 14　実験 II-ii：*SA* の行動選択確率の変化

Fig. 14.　Experiment II-ii: The action probability of an *SA*.

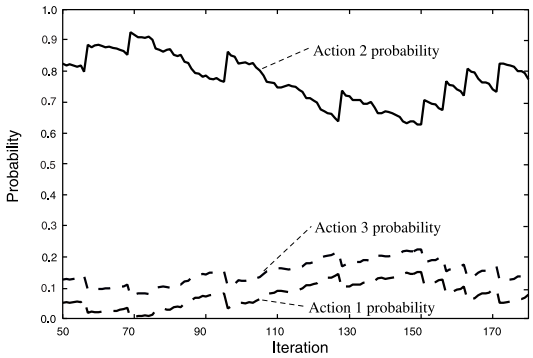


図 15　実験 II-ii：*SA* の行動選択確率の変化

Fig. 15.　Experiment II-ii: The action probability of an *SA*.

し，$SA^2$，$SA^3$ は，他 *SA* に追従するように行動 2 に収束している。

図 11 に利用者の平均待ち時間の変化を示す。グラフは 5 回の試行を行った平均である，また図 11 には，5 行動選択単位の移動平均を併せて示した。実験の結果から，利用者の平均待ち時間は，*SA* が行動選択を繰り返す毎に短縮されていることがわかる。

**〈4•3〉 計算機実験 II**　本実験では，ゾーン変更があった場合における本手法の環境変化への追従性について評価する。図 12 に計算機実験 II の実験環境を示す。

実験条件 II-i は，全てのかごが行動 3 を選択した場合に理論解と等しくなるゾーン設定に変化する実験環境である。これに対して実験条件 II-ii は，3 つの行動が直接的に理論解に結びつかないゾーン設定に変化する実験環境である。

**〈4•3•1〉 実験条件 II-i**　計算機実験 I と同様の環境において，50 行動選択まで実験を行い，行動 2 に行動選択確率がほぼ収束した状態でゾーン変更を生じさせる。本実験ではゾーンを縦方向 2 倍に拡張する。

**〈4•3•2〉 実験条件 II-i 結果および考察**　図 13 に代表的な *SA* の行動選択確率の変化例を示す。典型的な変化は，行動 3 を選択する確率が上昇し，行動 2 を選択する確率が低下する。また，他の *SA* も同様な結果となる。この結果から，ゾーンが 2 倍の大きさに変化した場合でも，各かごは自律的にかご間距離を調整し，ゾーン変化に追従した均等間隔運転を実現していることがわかる。

**〈4•3•3〉 実験条件 II-ii**　計算機実験 II-i と同様の条件でゾーンを縦方向 1.5 倍に拡張する。

**〈4•3•4〉 実験条件 II-ii 結果および考察**　図 14 および図 15 に代表的な *SA* の行動選択確率の変化を 2 例示す。図 14 は，行動 3，行動 2 の選択確率が入れ替わる典型的な例である。図 15 に示す例は，行動 2 が他の行動選択確率に比べ相対的に高いが，行動 3 の行動選択確率も低い確率ながらも維持されている典型的な例である。

実験条件 II-ii では，図 14 と同様の傾向を持つ *SA* と図 15 と同様の傾向を持つ *SA* が実験毎に違う割合で現れた。また，行動選択確率が低いながらも維持されている行動があることから，*SA* は，確率的に行動を選択する混合戦略をとっていると考えられる。

以上の結果から，*SA* が持つ行動の中に最適な理論解に相当する行動がない場合，各 *SA* は異なる行動を確率的に選択する混合戦略をとりながら，自律的に準最適な解に収束していると考えられる。混合戦略を考える場合，準最適な解は唯一であるとは限らないため，前述の実験結果は，収束した準最適な解が唯一でないことを示唆していると考え

られる。

## 5. む す び

本論文では，*LA* による適応的な行動選択が可能な MCE 制御手法について提案した。MCE シミュレータを用いた計算機実験から得られた知見により，*LA* を MCE 制御に応用する，これまでにない MCE 制御手法として産業利用上の可能性を示すことができた。

*LA* が学習した行動は，待ち行列モデルによる理論的な最適行動と一致し，ダンゴ状運転を避ける結果が得られた。さらに，環境の変化に追従して適切な戦略が自律的に獲得され，環境の変化に対する再設定なしに運用が可能であることを確認した。これより，*LA* による自律分散制御は，エレベータ利用者の平均待ち時間短縮，環境変化への対応に有効であることが明らかとなった。

今後は，より実際の運用に近い環境でのシミュレーションや，連続行動確率分布への拡張を図る予定である。

（平成 16 年 4 月 6 日受付，平成 16 年 8 月 26 日再受付）

## 文　献


（1） S. Hikita and S. Abe: “Elevator Group Control Systems Using AI Technologies”, *Journal of the Japanese Society for Artificial Intelligence*, Vol.17, No.1, pp.57–62 (2002-1) (in Japanese)
匹田志朗・阿部　茂：「エレベータ群管理制御における AI 技術の応用」, 人工知能学会誌, **17**, 1, pp.57–62 (2002-1)

（2） T. Tobita, A. Fujino, K. Segawa, K. Yoneda, and Y. Ichikawa: “A Parameter Tuning Method for Elevator Group Supervisory Control System By Using Genetic Algorithms”, *T. IEE Japan*, Vol.117-D, No.3, pp.306–313 (1997-3) (in Japanese)
飛田敏光・藤野篤哉・瀬川和宏・米田健治・市川芳明：「遺伝的アルゴリズムを応用したエレベータ群管理用パラメータ調整方法」, 電学論 D, **117**, 3, pp.306–313 (1997-3)

（3） M. Iwata, S. Hikita, and K. Komaya: “Detecting Elevator Traffic Patterns with Neural Networks”, *SICE*, Vol.33, No.3, pp.209–215 (1997-3) (in Japanese)
岩田雅史・匹田志朗・駒屋喜代俊：「ニューラルネットワークによるエレベータ交通流の検出」, 計測自動制御学会論文集, **33**, 3, pp.209–215 (1997-3)

（4） Y. Ogoshi, H. Kimura, S. Hirose, and N. Osato: “A Consideration on an Elevator Group Control System”, *IEICE*, Vol.J84-A, No.1, pp.22–32 (2001-1) (in Japanese)
小越康宏・木村春彦・広瀬貞樹・大里延康：「エレベータ群管理システムに対する一考察」, 信学論誌 A, **J84-A**, 1, pp.22–32 (2001-1)

（5） M. Miyatake, T. Koseki, and S. Sone: “A Proposal of Ropeless Lift System and Evaluation of its Feasibility”, *T. IEE Japan*, Vol.119-C, No.11, pp.1353–1360 (1999-11) (in Japanese)
宮武昌史・古関隆章・曽根　悟：「ロープレスエレベータシステムの提案とその有効性評価」, 電学論 D, **119**, 11, pp.1353–1360 (1999-11)

（6） H. Suzuki, S. Takahashi, Y. Sano, T. Sudo, S. Markon, and H. Kita: “Simulation-based Optimization of Multi-Car Elevator Controllers Using a Genetic Algorithm”, *SICE*, Vol.40, No.4, pp.466–473 (2004) (in Japanese)
鈴木裕通・高橋　聡・佐野康仁・須藤　豪・マルコン シャンドル・喜多　一：「遺伝的アルゴリズムによるマルチカーエレベータ制御ルールのシミュレーションベースド最適化」, 計測自動制御学会論文集, **40**, 4, pp.466–473 (2004)

（7） Y. Ogoshi, H. Kimura, S. Hirose, and N. Osato: “An Elevator Group Control System Using Multi-Agent System”, *IEICE*, Vol.J84-D-I, No.2, pp.191–202 (2001-2) (in Japanese)
小越康宏・木村春彦・広瀬貞樹・大里延康：「マルチエージェントシステムを用いたエレベータ群管理システム」, 信学論誌 D-I, **J84-D-I**, 2, pp.191–202 (2001-2)

（8） 高橋幸雄・森村英典：「混雑と待ち」(2001)

（9） K.S. Narendra and M.A.L. Thathachar: “*Learning Automata an Introduction*”, Prentice-Hall International (1989)

（10） M.L. Tsetlin: “On behavior of finite automata in random media”, *Automation and Remote Control*, Vol.22, No.11, pp.1345–1354 (1961)

（11） F. Qian and H. Hirata: “Learning Automata Modeling of Distributed Reinforcement Learning Systems with Collective Behavior”, *T. IEE Japan*, Vol.118-C, No.5, pp.787–793 (1998-5) (in Japanese)
銭　　飛・平田廣則：「分散強化学習システム：学習オートマトンのチームモデル」, 電学論 C, **118**, 5, pp.787–793 (1998-5)

（12） K. Shiraishi, T. Hamagami, S. Koakutsu, and H. Hirata: “Autonomous Driving Control for ITS by using Learning Automaton Network with Environments”, *T. IEE Japan*, Vol.123-C, No.7, pp.1285–1291 (2003-7) (in Japanese)
白石和章・濱上知樹・小圷成一・平田廣則：「複数環境学習オートマトンネットワークによる ITS 自律走行制御」, 電学論 C, **123**, 7, pp.1285–1291 (2003-7)

（13） A. Matsui and K. Matsuyama: “An Approach to Equilibrium Selection”, *Journal of Economic Theory* 65, pp.415–434 (1995)

（14） S. Aoki, Y. Iwai, M. Onishi, A. Kojima, and K. Fukunaga: “Learning and Recognizing Behavioral Patterns Using Position and Posture of Human Body and Application to Detection of Irregular State”, *IEICE*, Vol.J87-D-II, No.5, pp.1083–1093 (2004-5) (in Japanese)
青木茂樹・岩井嘉男・大西正輝・小島篤博・福永邦雄：「人物の位置・姿勢に注目した行動パターンの学習・認識と非日常状態検出への応用」, 信学論誌 D-II, **J87-D-II**, 5, pp.1083–1093 (2004-5)


## 付　録

### 1. *LA* の定義

*LA* を図 2 に示し，定義を以下に示す。

（定義） *RE* と $i$ 個の *SA* から構成される *LA* を以下の形式で定義する。

$SA^i$ ··· $i$ 番目の複数入力確率オートマトン

$RE$ ··· 未知環境

$Y^i$ ··· $SA^i$ の持つ行動集合
$Y^i = \{k(1), k(2), \cdots, k(l), \cdots, k(S)\}$
$S$ は $SA$ の持つ行動数

$y^i(t)$ ··· 時刻 $t$ における $SA^i$ の行動
$y^i(t) \in Y^i$

$\boldsymbol{p}^i(t)$ ··· 時刻 $t$ における $SA^i$ の行動選択確率分布
$\boldsymbol{p}^i(t) = \{p^i_{k(1)}(t), p^i_{k(2)}(t), \cdots, p^i_{k(l)}(t), \cdots, p^i_{k(S)}(t)\}$

$T^G$ ··· $SA$ の行動選択確率修正則
$\boldsymbol{p}^i(t+1) = T^G(y^i(t), r(t))$

$r(t)$ ··· 時刻 $t$ における $RE$ からの強化信号
REWARD:0，PENALTY:1
$r(t) = [0, 1]$

### 2. 行動選択確率修正則の定義

強化信号 $r(t)$ の入力を持つ $SA$ の強化法 $T^G$ の定義を以下に示す。

（定義）強化法 $T^G$ を以下のように定義する。ただし，時刻 $t$ における $SA^i$ の行動が $k(l)$ であった場合 $y^i(t) = y^i_{k(l)}(t)$ とする。

$$p^i_{k(l+I^i)}(t+1) = O_{S\epsilon^i(t+1)}(p^i_{k(l+I^i)}(t) + \theta^i(t+1)\Delta p^i_{k(l)}) \quad \cdots\cdots\cdots (付\ 1)$$

$$\left.\begin{aligned} p^i_j(t+1) &= O_{S\epsilon^i(t+1)}\left(p^i_j(t) - \frac{\theta^i(t+1)}{S-1}\Delta p^i_{k(l)}\right) \\ & j \neq k(l+I^i),\ j = k(1), \cdots, k(S) \end{aligned}\right\} \quad \cdots\cdots\cdots\cdots\cdots\cdots (付\ 2)$$

ただし

$$\Delta p^i_{k(l)} = \begin{cases} 0, \left( \begin{array}{l} y^i(t) = y^i_{k(1)}(t), \zeta^i < 0 \\ \text{OR} \\ y^i(t) = y^i_{k(S)}(t), \zeta^i > 0 \end{array} \right) \\ \\ \delta|\tau^i(\zeta^i(y^i_{k(l)}(t), r(t)))|, (\text{otherwise}) \end{cases} \quad \cdots\cdots\cdots\cdots\cdots\cdots (付\ 3)$$

$$I^i = \begin{cases} 0, \left( \begin{array}{l} y^i(t) = y^i_{k(1)}(t), \zeta^i < 0 \\ \text{OR} \\ y^i(t) = y^i_{k(S)}(t), \zeta^i > 0 \end{array} \right) \\ \\ \text{sign}(\zeta^i(y^i_{k(l)}(t), r(t))), (\text{otherwise}) \end{cases} \quad \cdots\cdots\cdots\cdots\cdots\cdots (付\ 4)$$

であり，$O_{S\epsilon^i(t+1)}$ は以下のような単体射影作用素である。

$$O_{S\epsilon^i(t+1)} = \left\{ p^i_j \geq \epsilon^i \geq 0, \sum_{j=1}^{s^i} p^i_j = 1 \right\} \cdots\cdots\cdots\cdots (付\ 5)$$

ただし，関数 $\zeta^i(\cdot)$ は，強化信号 $R(y^i_{k(l)}(t))$ によって決定する関数であり，$R(y^i_{k(l)}(t))$ は，観測期間 $u$ の間に $SA^i$ が行動 $k(l)$ を出力し得られた強化信号の最小値をとる。また関数 $\tau^i(\cdot)$ は $\tau^i(x) = x$ のような符号保留線形関数であり，$\theta^i$ は学習パラメータである。以下に，強化信号 $R(y^i_{k(l)}(t))$ を用いた強化信号指標関数 $\zeta^i(\cdot)$ の決定式を示す。

$$\text{if} : R(y^i_{k(l-1)}(t)) > R(y^i_{k(l)}(t)) > R(y^i_{k(l+1)}(t))$$
$$\zeta(\cdot) = 1, \delta = 1 \quad \cdots\cdots\cdots\cdots\cdots (付\ 6)$$

$$\text{if} : R(y^i_{k(l-1)}(t)) < R(y^i_{k(l)}(t)) < R(y^i_{k(l+1)}(t))$$
$$\zeta(\cdot) = -1, \delta = 1 \cdots\cdots\cdots\cdots\cdots (付\ 7)$$

$$\text{if} : R(y^i_{k(l-1)}(t)) < R(y^i_{k(l)}(t)) > R(y^i_{k(l+1)}(t))$$
$$\zeta(\cdot) = 0, \delta = -1 \cdots\cdots\cdots\cdots\cdots (付\ 8)$$

$$\text{otherwise} : \zeta(\cdot) = 0, \delta = 1 \cdots\cdots\cdots\cdots\cdots\cdots\cdots (付\ 9)$$


**白 石 和 章**（学生員） 1971 年 8 月 10 日生。2001 年広島国際学院大学電子工学科修士課程修了。同年，千葉大学大学院自然科学研究科人工システム科学専攻博士後期課程に入学，現在に至る。学習オートマトン，強化学習の研究に従事。

**濱 上 知 樹**（正員） 1966 年 3 月 7 日生。1988 年千葉大学工学部電気工学科卒業。セコム（株）勤務を経て，1999 年在職のまま千葉大学大学院自然科学研究科生産科学専攻後期課程修了。2001 年同助手。2004 年横浜国立大学助教授。大規模システムの数理，マルチエージェント，機械学習，創発システムの応用研究に従事。博士（工学）。IEEE，電子情報通信学会，情報処理学会会員。

**平 田 廣 則**（正員） 1948 年 6 月 2 日生。1976 年東京工業大学大学院電気工学専攻博士課程修了。同年千葉大学工学部助手，1981 年同助教授，1994 年同教授，1997 年同大学院自然科学研究科教授。大規模システムのモデリング，解析と設計，特に生態システム，VLSI レイアウト，並びに分散システムの基礎的理論に興味を持つ。工学博士。2001 年電気学会業績賞受賞。IEEE（Fellow），INNS，電子情報通信学会，情報処理学会，計測自動制御学会，システム制御情報学会，人工知能学会，日本数理生物学会会員。