

project_ex1 学术定位与相关工作综述

时间：2026-05-08 19:20:31（起稿）→ 21:30:00（v4 大修：以方法论文为目标重写问题定义 / 方法 / 指标 / 数据集四大模块；删去工程层叙事；加入 mermaid pipeline 图）

形式：与 AI 的学术讨论草稿，面向 paper writing

状态：v4 — 在 v3 基础上做的第四轮大修。重点重塑五件事：

- 删去 §5.1 工程贡献叙事（纯 reproducibility appendix 素材，不进 methodology）
- 用形式化 + 学术语言重写问题定义、I/O 范式与方法（§2 / §3）；不再使用 "rubric+iter_b" / "airouter vs miaocg" / "W2 §13.x" 这类内部代号
- 主推方法 = **LLM-as-STM-Judge**（§3）；含两张 mermaid pipeline 图（已通过 mmdc 11.14 渲染验证）
- 新增 §4 评测指标体系：每条 metric 给 formal definition + 设计意图 + 可靠性论证 + 与同类工作指标的诚实借鉴分析
- 新增 §5 数据集结构：4 subset × split × 适用实验三维表
- 不被现有实现限制，按 paper 章节级别写方法（实现细节进 reproducibility appendix）

0. 研究背景

0.1 问题缘起

LLM-as-Judge 范式 [1, 2] 在 NLP 自由文本评估上已成熟，但其向 SE artifact 评估的迁移仍处早期：现有 SE-domain LLM-as-Judge 工作主要集中在 code 与 review comment（见 §6.2），对 **graph-structured behavioral models**（含 **state machine**、**UML sequence diagram** 等）的覆盖刚起步（MCeT [12]、MermaidSeqBench [26]，均 2025），且几乎全部为 **single-shot** 实验——没有任何工作系统讨论 evaluator 自身的 stochasticity、provider drift 与 noise floor。这同时也是 SE 2030 vision paper [9] 点名的关键 research gap。

0.2 研究方向声明 — Software Engineering

本研究严格立足于 **SE 方向**，而非 NLP / ML 方向。这一定位影响所有决策——研究对象（SE artifact 而非自由文本）、关心的“质量”（结构正确性 / 形式化语义一致 / 工业可用性）、人评基准（资深工程师 / 评审专家）、研究范式（empirical / methodological + reproducible 实验脚手架）、典型投稿（TSE / TOSEM / EMSE / ICSE / FSE / ASE）。

1. 关键定义与术语（Definitions）

本节列出讨论中将反复出现的核心术语。每条均标注其属于“领域已有定义（含参考文献）”还是“本研究新造定义（含 rationale + 操作化方式）”。完整参考文献见 §14。

1.1 LLM-as-Judge

- 类型：领域已有定义
- 定义（采用 He et al. [9] 的形式化版本）：

$$\mathcal{E} : (T, C, X, R) \rightarrow (Y, E, F)$$

其中 $T \in \{\text{point-wise}, \text{pair-wise}, \text{list-wise}\}$ 是评估类型， C 是评估准则集合， X 是被评 candidate（单个或多个）， R 是可选 reference。输出 Y 是 graded / ranking / best-choice 形态的评估结果， E 是可选解释， F 是可选 feedback。

- 来源：MT-Bench / Chatbot Arena [1] (Zheng et al., NeurIPS 2023) 系统使用 "LLM-as-a-judge" 一词；G-Eval [2] (Liu et al., EMNLP 2023) 独立提出；He et al. [9] 给出上述正式定义
- 本研究采用形态：point-wise (单 STM 制品给绝对分)；pairwise / list-wise 留作扩展

1.2 Rubric (评分准则)

- 类型：领域已有定义 (教育评估 / NLG eval)
- 定义：把"质量"分解为 D 维 $\{d_1, \dots, d_D\}$ ，每维度配 (a) 维度描述 desc_d ；(b) L 个 level 的评分锚点 $\{a_{d,\ell}\}_{\ell=0..L}$
- 来源：教育评估学 (Brookhart [25])；Prometheus [4] 在 LLM-as-Judge 设定中系统化使用 "score rubric description" + "per-level score description" 双层结构
- 本研究操作化： $D = 7$ (A 覆盖 / B 准确 / C 具体 / D 证据 / E 校准 / F 可操作 / G 一致)， $L = 4$ (即 0/1/2/3 评分)

1.3 Anchored Rubric (锚定 rubric)

- 类型：本研究新造定义 (与 G-Eval auto-rubric 形成对照)
- 定义：评分维度 $\{d_i\}$ 与每维评分锚点 $\{a_{d,\ell}\}$ 由领域专家共识事先固定，inference 时直接作为 prompt 输入，不允许 LLM 在 **prompt-time** 自主生成或修改
- **rationale**：与 G-Eval [2] 的 auto-generated criteria 形成对照——auto 灵活但评分维度不可重复、跨实验不可比；anchored 牺牲灵活性换取纵向 (跨时跨 provider) 与横向 (跨论文) 可比性，是 methodology paper 实证纪律的前置条件
- 与 Prometheus [4] 的差异：Prometheus 训练数据使用 1k+ rubric 让 inference 时可任意输入 rubric；本研究固定 7 维 anchored，更严格

1.4 Form-filling

- 类型：领域已有定义
- 定义：把 LLM 评分任务约束为按预设 JSON / structured schema 填写各字段
- 来源：G-Eval [2] 首次系统化；与 OpenAI structured output / function calling 一脉相承
- 本研究操作化：每维度产出 $(\text{evidence_quotes}, \text{score}, \text{justification})$ 三元组的 JSON schema

1.5 Self-Consistency

- 类型：领域已有定义
- 定义：对同一输入做多次随机采样 (或同 prompt 多次调用)，对结果做 majority vote / 数值聚合
- 来源：Wang et al., ICLR 2023 [3]
- 本研究关系：借用多次采样手段，但用途不同——本研究多次重复是为了测量 **noise floor** (评估 evaluator 自身 **stochasticity**)，不是 vote 一个更可信结果 (详见 §1.7)

1.6 Noise Floor (噪声基底)

- 类型：本研究新造定义 (借自信号处理 / 测量学)
- 定义：在 candidate 配置完全固定 (同 prompt、同 model snapshot、同 input、同 provider) 情况下，多次重复实验得到的某 metric 的标准差 σ 。任何 metric 改进若小于 3σ ，应被视为 noise 内涨落而非真实改进
- **rationale**：当 evaluator 自身的 σ 与待测改进效果同量级时，single-shot 数字毫无说服力。引入 noise floor 是把 evaluator stability 显式纳入 SE 评估方法学
- 操作化：k-rep 协议 (默认 $k = 5$) + 报告 $(\bar{x}, \sigma, \text{provider snapshot})$ 四元组；任何 promotion claim 须 $\geq 3\sigma$
- 来源对照：empirical SE 中已有 replication studies 概念 (Carver [23]、Juristo & Vegas [23])，但未在 LLM-as-Judge 评估上系统使用

1.7 Provider Drift / Cache Effect

- 类型：本研究新造定义
- 定义：
 - **Provider drift**: 同一名义 model 在不同 provider（直连 / 第三方代理 / 自托管）或不同时间窗口下，输出分布出现系统性偏移
 - **Cache effect**: 第三方 provider 的 prompt-response cache 命中后返回相同 response，使重复实验的 σ 估算偏低、noise floor 估计失真
- **rationale**: 现有 LLM-as-Judge 文献几乎不讨论；但实证发现 **cache 命中可使 σ 偏小约 50%**，掩盖真实 noise floor
- **操作化**: 每条实验记录 4 元组中的 provider 字段必须含 provider name + model snapshot + commit; strict mode 拒绝任何 silent fallback

1.8 STM Artifact（状态机制品）

- 类型：本研究操作化
- 定义：在 $NL \rightarrow$ state machine 工件流末端产出的状态机表示，形式化为五元组 $M = (S, E, V, T, A)$ — S 状态集、 E 事件集、 V 变量集、 $T \subseteq S \times E \times G(V) \times A^* \times S$ 带守卫迁移集、 A 动作集；可扩展为含时钟约束 C 与不变式 Inv 的时间状态机 $M_T = (S, S_0, E, V, C, T, \text{Inv}, A)$
- 来源：经典 state machine 自 Hopcroft & Ullman [21]；时间自动机自 Alur & Dill [22]
- 本研究操作化：[./state machine review corpus/](#) 6 篇文献已对齐到统一 schema，含 UML SM / SysML SM / Statechart / Protocol SM / FSM 多家族

1.9 Inter-rater Agreement / Cohen's κ

- 类型：领域已有定义
- 定义： $\kappa = (p_o - p_e) / (1 - p_e)$ ， p_o 是观察一致率， p_e 是随机一致期望
- 来源：Cohen [20]
- 本研究使用：作为 STM review corpus 入选硬条件；目标是与已报告 κ 的工作（PSMBench $\kappa = 0.82$ states / $\kappa = 0.78$ transitions）对齐

2. 问题定义与 I/O 范式

2.1 形式化问题陈述

目标：构造一个 judge 函数 $\mathcal{J}$ 使其能自动产出与人类专家 review 高度对齐的 STM 制品评审报告。

形式化：

$$\mathcal{J} : (R, M, \Phi) \rightarrow Y$$

其中：

- R — 自然语言需求文档集合（NL requirements）
- $M = (S, E, V, T, A)$ — STM 制品（定义 §1.8）
- $\Phi = (\{d_i\}_{i=1..D}, \{a\{d, \text{ell}\}\}, \{\text{desc}_d\})$ — anchored rubric（定义 §1.3）
- $Y \in \mathcal{Y}$ — 评审报告，结构见 §2.2

2.2 输出范式（review report 结构）

$$Y = \{(s_d, \mathbf{E}_d, j_d)\}_{d=1..D}$$

每维度产出三元组：

字段	类型	含义
s_d	$\{0, 1, \dots, L\}$	离散 score（本研究 $L = 3$ ）
$\mathbf{E}_d$	$\text{List}[\text{string}]$	来自 R 或 M 的 evidence quotes 列表，每条须可在原文定位
j_d	string	自然语言 justification，解释为何打这个分

2.3 多次重复 + Noise Floor 协议

定义 k -重复 judge：

$$\mathcal{J}_k(R, M, \Phi) = \{Y^{(1)}, Y^{(2)}, \dots, Y^{(k)}\}$$

每维度统计量：

$$\bar{s}_d = \frac{1}{k} \sum_{i=1}^k s_d^{(i)}, \quad \sigma_d = \sqrt{\frac{1}{k-1} \sum_{i=1}^k (s_d^{(i)} - \bar{s}_d)^2}$$

最终输出：

$$\bar{Y} = \{(\bar{s}_d, \sigma_d, \mathbf{E}_d^{\cup}, j_d^*)\}_{d=1..D}$$

其中 $\mathbf{E}_d^{\cup}$ 是 k 次的 evidence 并集， j_d^* 是被多数 rep 共享的 justification。

2.4 评估目标（quality measure）

设 H 为人类专家 review，含 ground-truth 分 h_d 。

Per-dim 对齐：

$$\rho_d = \text{Pearson}(\bar{s}_d, h_d), \quad \text{MAE}_d = \frac{1}{N} \sum_n |\bar{s}_{d,n} - h_{d,n}|$$

Overall 对齐：通过 §4 定义的 composite metric ScoreAlign / RAS / SAS / CRAS / HAI 度量。

2.5 Promotion 决策规则（noise-floor-aware）

候选配置 Φ 相对 baseline Φ_0 的真实改进判定：

$$\Phi' \succ \Phi_0 \iff \text{HAI}(\Phi') - \text{HAI}(\Phi_0) > 3 \hat{\sigma}_{\text{HAI}}$$

其中 $\hat{\sigma}_{\text{HAI}}$ 是 baseline 在 k -rep 协议下的实测 HAI 标准差。这条规则把 **noise floor** 显式纳入 SE 评估方法学，是本研究 **N1** 创新的核心。


3. 我们的方法 — LLM-as-STM-Judge

3.1 方法概述

提出 **LLM-as-STM-Judge**: 一个 prompting-only、anchored-rubric、noise-floor-aware 的 judge 函数 $\mathcal{J}$, 落地为 4 个连续 stage:

Stage	名称	目的
1	Preparation	把 STM 制品 M 文本化、聚合 review context C
2	Per-dimension Form-filling	对每个 anchored 维度 d 调用 strict-LLM 产出 $(s_d, \mathbf{E}_{d,j_d})$
3	Single-rep Aggregation	把 D 维度组合为单次 review 报告 $Y^{(i)}$
4	Multi-rep Stability Characterization	k 次重复后输出 $(\bar{Y}, \sigma)$ 与 noise floor

3.2 整体 pipeline



3.3 Stage 1 — Preparation


输入: R, M, Φ 。

步骤:

- 1. **Textualize M** : 把状态机制品序列化到一个稳定的 DSL (PlantUML / pyfcstm / Mermaid) ; 保留状态、迁移、守卫、动作的可定位文本片段
- 2. **Bind context C** : 将 R 、textualized M 、 Φ 拼成 review context, 供后续 per-dim 调用复用
- 3. **Schema lock**: 固定 prompt template、JSON output schema、temperature τ 、max retries n

输出: $C = (R, M_{\text{text}}, \Phi, \text{schema})$ 。

3.4 Stage 2 — Per-dimension Form-filling (详细)



Strict-LLM 调用的关键约束：

- **No silent fallback**：任何 LLM 端 fail 必须显式抛出，不允许偷偷走 deterministic 兜底（这是 noise floor 协议成立的前置条件）
- **Schema-validated**：响应不通过 JSON schema 校验则触发 `n` 次有限 retry，超过后抛错
- **Provider-aware**：每次调用记录 provider snapshot（name + model version + commit）

3.5 Stage 3 — Single-rep Aggregation

把 D 维度结果聚合为单次 review 报告：

$$Y^{(i)} = \{(s_d, \mathbf{E}_d, j_d)\}_{d=1..D}^{(i)}$$

并把 $Y^{(i)}$ + 元数据（provider snapshot、调用耗时、retry 次数）落到 **per-task JSON checkpoint**，使 rep 中途失败可断点续跑。

3.6 Stage 4 — Multi-rep Stability Characterization

外层重复 k 次 Stage 1→3，得到 $\{Y^{(1)}, \dots, Y^{(k)}\}$ 。计算：

量	公式
维度均值	$\bar{s}_d = \frac{1}{k} \sum_i s_d^{(i)}$
维度标准差	$\sigma_d = \sqrt{\frac{1}{k-1} \sum_i (s_d^{(i)} - \bar{s}_d)^2}$
Noise floor (HAI 整体)	$\hat{\sigma}_{\text{HAI}} = \sqrt{\frac{1}{k-1} \sum_i (\text{HAI}^{(i)} - \overline{\text{HAI}})^2}$
Stability score	$\text{Stability} = 1 - \frac{1}{D} \sum_d \frac{\sigma_d}{\sigma_d^{\max}}$ ，其中 $\sigma_d^{\max}$ 是该维度可能的最大 σ （基于 score range）

输出 **bundle**：

$$\bar{Y} = (\bar{s}_d, \sigma_d, \mathbf{E}_d^{\cup}, j_d^*)_{d=1..D} \cup (\hat{\sigma}_{\text{HAI}}, k, \text{provider snapshot})$$

3.7 与现有方法的方法学差异

维度	G-Eval [2]	MT-Bench [1]	Prometheus [4]	MCeT [12]	MermaidSeqBench [26]	本研究
Rubric 来源	auto-gen	per-task	inference-time (trained 1k+)	atomic + perspective	6-dim anchored	7-dim anchored
评判对象	NLG	dialog	NLG	sequence diagram	sequence diagram	state machine
多次重复	✗	✗	✗	✗	✗	✔ k=5
Noise floor	✗	✗	✗	✗	✗	✔
Provider drift	✗	✗	n/a self-host	✗	✗	✔
Strict-no-fallback	n/a	n/a	n/a	n/a	n/a	✔
Schema-validated form-filling	✓	partial	✓	partial	✓	✔
Evidence quoting	✗	✗	partial	✓	✗	✔

唯独本研究同时满足**"7-dim anchored + 多次重复 + noise floor + provider drift + strict-no-fallback + evidence quoting"**——这是 §8.5 所列 N1 创新的具体落点。

4. 评测指标体系

本节对每个我们使用的指标给出 (a) formal definition; (b) 设计意图（量什么）；(c) 为什么可靠；(d) 借鉴自哪些既有指标。最后给出对同类工作所用指标的横向对比与诚实借鉴分析（§4.6）。

4.1 ScoreAlign — 单 candidate 单维分数对齐度

$$\text{ScoreAlign} = 100 \cdot \left[0.4 \cdot (1 - \text{MAE}) + 0.3 \cdot \frac{\rho_S + 1}{2} + 0.3 \cdot \text{hit@0.05} \right]$$

其中 ρ_S 是 Spearman rank correlation, $\text{hit@0.05} = \frac{1}{N} \sum_n \mathbb{1}_{[|\bar{s}_n - h_n| \leq 0.05]}$ 。

项	内容
量什么	LLM 与 human 单点分数的对齐质量，含绝对误差（MAE）+ 排序一致性（Spearman）+ 容差命中率（hit@0.05）三个互补维度
为什么可靠	(1) 三项加权设计避免单一指标过度敏感（e.g. MAE 对 outlier 敏感、Spearman 对 tie 敏感、hit 对阈值敏感）；(2) 与 human review 对照，使用人评作 ground truth；(3) 0.4/0.3/0.3 权重经 baseline 反复验证可在小样本下稳定
借鉴自	MAE 与 Pearson — Prometheus [4] / UML-Assessment [13] / CodeJudge [11] 都用； hit@τ — 信息检索 / recommender systems 的经典 metric

4.2 RAS — Record Alignment Score（record-level 综合）

$$\text{RAS} = 0.30 \cdot \text{ScoreAlign}^{(\text{rec})} + 0.25 \cdot \text{IssueF1} + 0.20 \cdot \text{ReasonAlign} + 0.15 \cdot \text{EquivAlign} + 0.10 \cdot \text{Calib}$$

项	内容
量什么	record-level（per-sample 评审）的多维综合对齐：分数对齐 + 问题识别 F1 + reason 对齐 + 等价性识别 + 校准性
设计动机	单一 ScoreAlign 仅刻画"分对不对"；RAS 把"评审质量"分解为 5 个互不冗余维度，避免 LLM 仅猜中分数但 reasoning 错误时仍被高估
为什么可靠	5 个子项各有独立监督信号（IssueF1 ↔ human-flagged issues；ReasonAlign ↔ human reason set；EquivAlign ↔ semantic equivalence labels；Calib ↔ confidence vs accuracy gap）；权重总和 1，加权后值域 [0,100]
借鉴自	多 metric 加权综合思路与 MT-Bench [1] 的 multi-metric eval 同源； IssueF1 借鉴 MCeT [12] 的 issue-level precision/recall； Calib 借鉴 Tian Verbalized Confidence [6] 的 ECE 思路

4.3 SAS — Summary Alignment Score（summary-level 综合）

$$\text{SAS} = 0.40 \cdot \text{ScoreAlign}^{(\text{sum})} + 0.25 \cdot \text{RankAlign} + 0.20 \cdot \text{EvidenceDiscipline} + 0.15 \cdot \text{Stability}$$

其中 RankAlign 是 candidate 间两两排序准确率（pairwise order accuracy）， $\text{EvidenceDiscipline}$ 是 evidence quote 是否能在原文定位的合规率， Stability 是 k-rep 内的稳定性。

项	内容
量什么	summary-level（case 聚合）的多维综合：聚合分对齐 + 排序一致 + evidence 合规 + 重复稳定
设计动机	summary 视角的 LLM 评估容易被 verbosity bias 推高（写得多就显得评得好），加入 EvidenceDiscipline + RankAlign 作为正交监督
为什么可靠	RankAlign 直接抓 ranking quality（候选间相对优劣是 LLM-as-Judge 的核心能力之一，参考 MT-Bench [1] 的 pairwise judge）；EvidenceDiscipline 抓 hallucination；Stability 抓 noise floor 派生量
借鉴自	RankAlign 是 MT-Bench [1] pairwise accuracy 的 pointwise 等价量； EvidenceDiscipline 是本研究新设，灵感来自 CRScore [27] 的 grounded-claim alignment； Stability 来自 §1.6 noise floor 概念

4.4 CRAS — Component Review Alignment Score（component-level 综合）

$$CRAS = 100 \cdot \min\left(1, 0.45 \cdot \frac{ScoreAlign}{100} + 0.35 \cdot macro_F1 + 0.20 \cdot hit@0.05\right)$$

项	内容
量什么	component-level（per-construct 如 state / transition / guard）评审的对齐度，分数对齐 + 标签 F1 + 高精度容差命中
设计动机	component-level 评审天然带分类标签（构件类型），需要把分类对齐（macro_F1）与回归对齐（ScoreAlign）放一起
为什么可靠	macro_F1 解决 class imbalance（structure-and-event-driven 数据集 7 类构件分布不均）；hit@0.05 提供高精度容差信号
借鉴自	macro_F1 是 NLP 经典 metric，PSMBench [14] 也用 component-level F1； ScoreAlign + macro_F1 加权是本研究新组合

4.5 HAI — Human Alignment Index（顶层综合）

$$HAI = 0.40 \cdot RAS + 0.30 \cdot SAS + 0.30 \cdot CRAS$$

PDS（Protocol Discipline Score）以 binary gate 形式参与 promotion 决策：

$$promote(\Phi') \iff HAI(\Phi') - HAI(\Phi_0) > 3\hat{\sigma}_{HAI} \wedge PDS(\Phi') \geq 95$$

项	内容
量什么	三个 record/summary/component 视角的人评对齐度的综合
设计动机	顶层 single number，方便 PR / paper 报告"提升了多少"；但单独 HAI 不能用于 promotion 决策——必须配合 noise floor + PDS gate
为什么可靠	0.4/0.3/0.3 权重让所有三层视角都"会动"；PDS 作 binary gate 防止 protocol-style overclaim 退化
借鉴自	HAI 风格的 single composite 与 LLM-as-Judge 文献中 SAS（Spearman / Agreement Score）/ Pearson 等单 number reporting 一脉相承； 3σ promotion rule 是本研究新加的方法学纪律，借自工业 SPC（statistical process control）

4.6 同类工作的指标体系横向对比

论文	主指标	与人评对齐方式	是否多seed	是否含stability
G-Eval [2]	per-criterion score average	Spearman / Kendall vs human	✗	✗
MT-Bench [1]	win rate / Elo / agreement	agreement % with human pairwise	✗	✗
Prometheus [4]	per-sample 1-5 score	Pearson / Kendall with GPT-4 + human	✗	✗
JudgeLM [7]	A/B/Tie verdict	agreement % with GPT-4	✗	✗
CodeJudge [11]	binary correct + per-error severity	Pearson / Spearman / accuracy	✗	✗
UML-Assessment [13]	total score 0-40	Pearson / MAE vs 3 TAs	✗	✗
MCeT [12]	issue list	precision / recall vs engineers	✗	✗
MermaidSeqBench [26]	6-dim 0-1	per-dim agreement vs human	✗	✗
CRScore [27]	3-dim score	Spearman = 0.54 with human	✗	✗
RESpecBench [28]	binary verdict	disagreement vs sound verifier	✗	partial
本研究	5-layer hierarchy: ScoreAlign → RAS/SAS/CRAS → HAI	MAE + Spearman + hit@τ + macro_F1	✓ k=5	✓ Stability

4.7 诚实借鉴分析

我们的指标	借鉴成分	新增成分
ScoreAlign	MAE / Spearman 是 Prometheus / CodeJudge / UML-Assessment 共有; hit@τ 是 IR 经典	三项加权 (0.4 / 0.3 / 0.3) 的具体设计是本研究的; 权重经 W3 baseline 反复实证调出
RAS / SAS / CRAS	加权综合多 sub-metric 的形态与 MT-Bench [1]、Prometheus [4] 同思路	把 SE artifact 评审拆为 record / summary / component 三视角是本研究新设
IssueF1	issue-level precision / recall 借自 MCeT [12]	应用到 STM artifact 是新场景
Calib	校准误差思路借自 Tian Verbalized Confidence [6] / ECE 文献	与 confidence-formula 的 SE 工程化集成是新场景
EvidenceDiscipline	grounded-claim alignment 思路借自 CRScore [27] 的 neuro-symbolic grounding	把"evidence 是否可在原文定位"作为独立 sub-metric 是本研究新加
Stability	本研究新设, 源自 \$1.6 noise floor 协议	完全 novel: 现有 LLM-as-Judge 文献无人单独 metric 化
HAI 三层加权 + 3σ promotion + PDS gate	composite score 思路与 SAS / Pearson 一脉相承	3σ promotion rule + binary PDS gate 是本研究新方法学纪律, 无既有 LLM-as-Judge 文献先例

结论: 我们的指标体系没有发明新的 **atomic metric** (MAE / Spearman / F1 / hit@τ 都是既有), 但把它们按 **SE artifact judging** 的需求层级化组合, 并首次引入 **noise floor + 3σ promotion + PDS gate** 作为顶层方法学纪律 — 这才是本研究在指标层面的真正学术贡献。

5. 数据集结构

本研究依托 [./state machine review corpus/](#) 6 篇文献整理出的统一 schema 数据集。本节给出数据集的 4 个 subset、其性质、与可支撑的实验类型。

5.1 总览

Subset	Record type	来源	行数	评分粒度	reviewer 资质
A. record-level	sample_level_review	llms_emp [16]	192	per-sample (一个 sample = 一个生成的 SysML 行为模型)	SE 研究者
B. summary-level	summary_level_run_score / case_aggregate_stat / raw_score_row / summary	ttool-ai [15] (116) + psmbench [14] (126 LLM run scores) + rfcnlp [18] (4)	246 + 部分	per-case 聚合	学生 + 系统工程师 / domain expert
C. component-level	component_level_review	structure-and-event-driven [19]	512	per-construct (7 类: state/transition/guard/action/hierarchical/parallel-region/history)	121 学生 (3 大学 senior/grad) + 任务训练
D. protocol-level	case_aggregate_stat	psmbench [14] (14) + hermes [17] (3) + rfcnlp [18] (6)	23	per-protocol (一个完整协议 RFC → PSM)	协议域 expert + cross-verified

合计 **973 行** (baseline 820 + protocol-FSM 新增 153)。

5.2 各 subset 详细描述

5.2.1 Subset A — record-level (finest granularity)

- 结构：每行一个 sample，含 (NL requirement, generated artifact, human score 0-1, multi-dim quality breakdown, reviewer notes)
- 来源：llms_emp 192 行 SysML 行为模型生成 sample，多 LLM × 单/双阶段配置
- 数据特点：
 - 评分尺度：normalized 0-1
 - 多维细分：含语法准确率 + 语义一致性 F1 多维度
 - 仅聚合（无 raw reviewer-by-reviewer），但多维细分已存
- 可支撑的实验：
 - ρ_d 、 MAE_d 直接对齐
 - record-level RAS 主要在此 subset 上计算
 - rubric ablation（7 维 → 6 维 / 5 维）的对照实验（每改 1 维测在 192 行上的 ScoreAlign 改变）
 - W2 confidence-formula bug 的 motivating example（subset A 是触发 bug 的最直接数据）

5.2.2 Subset B — summary-level (case 聚合)

- 结构：每行一个 case 的聚合分（如 ttool-ai 的"PlatooningSystem 整体得 81/100 块图，63/100 STM"），或 psmbench 的"BGP 协议下 GPT-4 跑分 = 0.85 PSM_combined_F1"
- 来源：ttool-ai 116 行 + psmbench 126 LLM run scores + rfcnlp 4 行；混合 record_type
- 数据特点：
 - 评分尺度：ttool-ai 0-100 likert / psmbench 0-1 F1 / rfcnlp 0-1 macro_F1（混合 → 必须各自归一化后才能合一）
 - 含 raw_score_row 可拆出 reviewer 个人粒度（ttool-ai 30 raw rows）
 - 多 LLM × 多协议 × 多 case 的笛卡尔积，适合做 LLM 排序
- 可支撑的实验：
 - SAS 主要在此 subset 上计算
 - RankAlign (pairwise order accuracy) 的 LLM 间排序对齐
 - LOFO (leave-one-family-out) 泛化实验
 - 跨论文 schema-aligned reporting（同一 stub 下三家 review 维度对照）

5.2.3 Subset C — component-level (最大数据量，最细分类粒度)

- 结构：每行一个 (paper, case, LLM, construct_type) 的 TP/FP/FN → component F1 $\in [0, 1]$
- 来源：structure-and-event-driven 512 行；4 generation strategies × 多 LLM × 8 reactive systems × 7 construct types
- 数据特点：
 - 评分尺度：0-1 component F1
 - 7 类 construct 分布不均 (state / transition 居多，hierarchical / history 较少)
 - 数据量最大 (512 行) → 在小样本 corpus 中是稀缺资源
- 可支撑的实验：
 - CRAS 主要在此 subset 上计算
 - 7 维 rubric 与 7 类 construct 的对应实验（构件级别的 LLM 评审）
 - cross-LLM ranking with construct-type breakdown
 - per-construct LLM 错误模式分析（哪类 construct 是 LLM 短板）

5.2.4 Subset D — protocol-level (domain-specific high κ)

- 结构：每行一个完整协议（RFC）的 ground-truth PSM 与 LLM 抽取 PSM 的对照（state F1 + transition F1）
- 来源：psmbench 14 协议 / hermes 3 cellular spec / rfcnlp 6 protocol
- 数据特点：
 - 唯一含 **cross-verified $\kappa = 0.82$** （PSMBench states）的 subset
 - domain-specific（仅 protocol state machine）
 - 行数小（23）但每行是一个完整协议
- 可支撑的实验：
 - PDS（Protocol Discipline Score）专属
 - 高质量 ground truth → 适合做 LLM judge 与 sound oracle 的对照（类似 RESpecBench [28] 的双轨实验）
 - 跨 corpus 的 transfer：在 protocol 上训练 / 调 prompt 后测 generic STM 上的泛化

5.3 Splits (train / dev / validation / lockbox)

按 50% / 20% / 15% / 15% 分。**lockbox** 是 hold-out 严禁多次访问，仅用于最终 promotion 决策的最后一步检验。

Split	比例	用途
train	50%	rubric / prompt / pipeline 调试
dev	20%	中间评估
validation	15%	promotion 候选筛
lockbox	15%	每个 candidate 配置只测 1 次，用于最终晋升验证；噪声 floor 在 lockbox 上重新校准

5.4 Subset × 实验适用性矩阵

实验类型	Subset A	Subset B	Subset C	Subset D
ScoreAlign 计算	✓	✓	✓	● (用 F1)
RAS (record 综合)	✓ 主	●	●	●
SAS (summary 综合)	●	✓ 主	●	✓
CRAS (component 综合)	●	●	✓ 主	●
PDS (protocol 综合)	●	●	●	✓ 主
Noise floor (k-rep σ 估计)	✓	✓	✓	✓
Provider drift (跨 chain mean shift)	✓	✓	✓	✓
Rubric ablation (7→6→5 维 ScoreAlign 改变)	✓ 主	✓	●	●
LOFO 泛化	✓	✓	✓	●
Cross-LLM ranking	●	✓ 主	✓	✓
Sound oracle 对照 (类 RESpecBench [28])	●	●	●	✓ 主

关键观察：

- **Subset A** 是 **W2 confidence-formula bug** 的首发地，方法学论文 §Motivation 的 motivating example 应来自此 subset
- **Subset D** 是与 **RESpecBench [28]** 双轨设计能对接的唯一 **subset** (因为只有它有 sound ground truth)
- **Subset C** 因量最大，是 N4 (5-rep 用于 noise floor 而非 vote) 的主战场

6. 相关工作

6.1 Generic LLM-as-Judge 方法学（自由文本主流）

7 篇代表性工作已建库 ([llm as judge methods corpus/](#))。

Slug	LLM method	评判对象	输入	输出	rubric
g-eval [2]	Pure prompting + form-filling + CoT + auto-rubric	NLG (dialog summary / news summary)	(Task description + auto-generated criteria + Source + Output)	Pointwise score	auto-gen
mt-bench [1]	Pure prompting + pairwise + position-bias swap	LLM dialog (80 prompts × N model)	(Q + A) 或 (Q + A + B)	(a) pointwise 1-10; (b) pairwise A/B/Tie	partial
self-consistency [3]	同 prompt 多次采样 + majority vote	推理任务	Question	多 reasoning chain → vote	✗
constitutional-ai [5]	Critique-then-revise + RLAIIF	LLM safety	(Prompt + Initial response + Constitution)	Revised response	partial
tian-verbalized-confidence [6]	LLM 自报 confidence	LLM 自答	(Q + A + "请给 confidence")	0-1 / linguistic confidence	●
prometheus [4]	Fine-tune Llama2-13B + 1k+ rubric	Generic NLG	(Instruction + Response + Rubric desc + Per-level desc)	(Feedback + 1-5)	✓
judgelm [7]	Fine-tune Vicuna pairwise	自由文本	(Q + A + B)	A/B/Tie	weak

这条线索的 **generic** 局限：全部 single-shot；无 noise floor；无 provider drift；评测对象是 generic 文本。

6.2 SE-artifact / SE-reliability LLM-as-Judge (7 篇)

Slug	评判对象	方法	与 STM 接近度	关键发现
code-judge [11]	LLM 生成代码	Pure prompting + slow-thinking (analyze-summarize / 9-class taxonomy)	● 同 SE 大类	test-case-free; vs SOTA Pearson +12-42%
cr-score [27]	code review comment	多维 review-quality + neuro-symbolic	● 评 review ● 不评 artifact	0.54 Spearman with human
uml-diagram-assessment [13]	UML class diagram	Pure prompting + anchored rubric + few-shot; 3 LLM vs 3 TA	● UML 同源 (structural)	Pearson > 0.76 / MAE < 4
mcet [12]	UML sequence diagram	Atomic + multi-perspective + cross-check self-consistency	✓ 最接近	precision 0.58 → 0.81
mermaid-seq-bench [26]	Mermaid SD	Benchmark + 6 fine-grained dimensions	✓ 同源	132 sample; 多 SOTA LLM judges 揭示 capability gaps
respec-bench [28]	NL → formal spec	Sound verifier 反向验证 LLM judge	● formal spec	LLM judge 严重高估 spec 正确性
code-to-courtroom [9]	综述	SE 2030 vision	●	明确把 UML / formal spec / SM 列为 gap

这条线索的 **generic** 局限:

- 7 篇仍 single-shot / 无 noise floor / 无 provider drift
- 都未覆盖 state machine 类带 guards / temporal 的 behavioral model

6.3 STM 制品评估的现有 practice — 6 篇 review corpus

论文	年份 / Venue	评分尺度	reviewer 资质	inter-rater agreement
PSMBench [14]	2025 NeurIPS D&B	annotator A 提 → B 审	domain expert	$\kappa = 0.82$ / 0.78 ✓
TTool-AI [15]	2024 MODELSWARD	0-100 likert	学生 + 系统工 程师	学生 vs 专家对照 (无 κ)
llms_emp [16]	2025 Internetware	语法 + 语义 F1	SE 研究者	一致性讨论 (无 κ)
Hermes [17]	2024 USENIX Security	TCNL grammar 标注 + 双 expert verify	4 cellular researcher + 2 verifier	cross-verify 流 程; 2,800 person-hours
RFCNLP [18]	2022 IEEE S&P	XML grammar + Gold FSM	多 author 协 作 expert	标注/验证不同 author; 6 协议
structure-and- event-driven [19]	2026 arXiv	component-level F1	121 学生 + 任 务训练	component F1 单 点判定较客观

generic 局限: 每篇 schema 不同 / 跨论文不可比 / review 数据规模小 / reviewer 资质参差 / κ 报告稀疏。

6.4 STM 自动化评估 (automated metric) — baselines/ 62 篇主流

绝大多数用 BLEU / ROUGE / state count F1 / pass-fail / 作者主观, 少数尝试 LLM-judge 但都用 metric 判断而非真 LLM-as-Judge (详见 [project 1.../baselines/](#))。

7. 现有方法的 4 个核心局限

#	局限	谁碰过	我们的应对
L1	无 noise floor — 单 shot	§6.1 + §6.2 共 14 篇 LLM-as-Judge 文献 + 几乎所有 STM-generation 论文	✓ k-rep + $\hat{\sigma}$ + 3σ promotion
L2	provider/cache 效应被忽略	LLM-as-Judge 文献完全不讨论	✓ per-task ckpt + 跨 chain 对照
L3	rubric 不锁定	G-Eval auto / Prometheus inference-mutable / MCeT atomic-only / MermaidSeqBench 6-dim 但缺 evidence	✓ 7 维 anchored + evidence quoting
L4	无 STM 专用 review-quality framework	全部 14 篇 LLM-as-Judge + STM 现有 practice 都未覆盖	✓ 7 维框架 (A-G)

7.1 14 篇 LLM-as-Judge 文献在 L1-L4 上的横向空缺

论文	评判对象	L1 noise	L2 drift	L3 anchor	L4 STM
G-Eval [2]	NLG	✗	✗	✗ auto	●
MT-Bench [1]	dialog	✗	✗	partial	●
Self-Consistency [3]	reasoning	partial (vote)	✗	✗	●
Constitutional AI [5]	safety	✗	✗	partial	●
Verbalized Confidence [6]	LLM 自答	partial	✗	●	●
Prometheus [4]	NLG	✗	n/a	✓ inference	●
JudgeLM [7]	dialog	✗	n/a	weak	●
CodeJudge [11]	code	✗	✗	partial	●
CRScore [27]	review comment	✗	✗	✓ 3 维	● 不评 artifact
UML-Assessment [13]	class diagram	✗	✗	✓	● structural
MCeT [12]	sequence diagram	✗	✗	partial	✓ behavioral, 缺 guards/temporal
MermaidSeqBench [26]	sequence diagram	✗	✗	✓ 6 维	✓ 同上
RESpecBench [28]	formal spec	partial (bias)	✗	n/a	● 但 reliability 同向
Code-to-Courtroom [9]	survey	n/a	n/a	n/a	gap 已点名
本研究	STM artifact	✓ k-rep + σ	✓ per-task ckpt	✓ 7 维 anchored	✓ STM

8. 学术贡献分层与诚实创新点分析

本节去掉了 v3 的 §5.1 工程贡献叙事（纯 reproducibility appendix 素材，不进 methodology）。

8.1 方法学贡献（主推）

- 1. **LLM-as-STM-Judge**（详见 §3） — 一个 prompting-only、anchored-rubric、noise-floor-aware 的 judge 函数 $\mathcal{J}$ 。这是本研究的主方法。
- 2. **Noise-floor-aware Promotion Rule** (§2.5) — 把 evaluator 自身的 stochasticity 作 first-class concern，要求任何配置改进必须 $\geq 3\hat{\sigma}_{\text{HAI}}$ 才算真改进。
- 3. **Layered Alignment Metric Hierarchy** (§4) — ScoreAlign $\rightarrow$ RAS / SAS / CRAS $\rightarrow$ HAI 五层，每层有不同的人评对齐 sub-signal（IssueF1 / ReasonAlign / EvidenceDiscipline / Stability / macro_F1 等），顶层用 PDS binary gate 防 overclaim 退化。

8.2 实证贡献

1. 配置变体下的多维 **trade-off** 量化 — 不同 rubric / prompt / pipeline 变体在 calibration 与 score-alignment 上呈现互斥关系；single-number HAI 改进会掩盖此 trade-off。需多维分解后才能看清。
2. **Self-Consistency** 在锁定结构化任务上的失效 — 在 anchored rubric + locked output schema 下，sample-level variance 接近 0，使 majority-vote 形态的 SC 既无聚合增益也不能用作 noise 估计；多次重复必须用于 noise floor 测量而非 vote。这是对 SC [3] 在结构化判定任务上局限的**实证刻画**。
3. **Cross-provider** 同 **config** 的均值漂移与方差掩盖 — 同 model / 同 config 在不同 provider chain 下 mean shift 在亚 σ 量级 ($< 0.1\hat{\sigma}$)；但 σ 估计本身因 cache 命中可被压低 ~50%，使得 single-provider single-shot 实验的 noise floor 严重低估。

8.3 领域贡献

1. **7 维度 STM review-quality framework** (A 覆盖 / B 准确 / C 具体 / D 证据 / E 校准 / F 可操作 / G 一致性)
2. 跨 6 篇文献 **review schema** 对齐 (PSMBench / TTool-AI / llms_emp / Hermes / RFCNLP / structure-and-event-driven)

8.4 数据贡献（最弱）

当前 ~973 行 (baseline 820 + protocol-FSM 153)，缺 Path C 自补 human review benchmark (< 1000 不足以独立 publish 数据集论文)。

8.5 诚实创新点矩阵 (N1-N6)

#	创新点	是否真新	与最近相关工作的差异
N1	Noise-floor-aware methodology for SE-artifact LLM-as-Judge	● 真新	§6.1 + §6.2 共 14 篇都没做；首次工程化操作到 LLM-as-Judge
N2	Anchored rubric + form-filling + evidence quoting 三件套	● 方法增量	UML-Assessment [13] 已有 anchored rubric；Prometheus [4] inference-time rubric；本研究的差异是 evidence quoting 的强 schema 与 strict-no-fallback
N3	STM artifact 域 7 维评审框架	● 领域内首次	已有 STM eval (PSMBench F1 / TTool-AI likert) 都是单维或低维；7 维设计本身受 NLG eval 多维 rubric 启发
N4	"k-rep aggregation 用于 noise floor 测量而非 vote"	● 新颖应用	Self-Consistency [3] 用 multi-sample 做 vote；我们用相同 multi-sample 做 stability characterization
N5	Confidence-formula bug 类的 motivating example	● 真新	UML-Assessment [13] 也报告类似 bug 但只当 limitation；本研究升级为方法学论述核心 case
N6	跨 6 篇异构 STM review schema 对齐	● 数据工程	不算方法学创新，但是 reproducibility appendix 的 strong contribution

总评：真实学术内核 = **N1 + N4 + N5** (noise floor 协议、k-rep 转向、bug 类 motivating)；N2 是方法增量；N3 是领域内首次但概念借自 NLG eval。

8.6 诚实借鉴点矩阵

借鉴对象	我们怎么用	重要性
Prometheus [4] rubric desc + per-level desc 双层结构	7 维 rubric form-filling 直接对应	高
G-Eval [2] form-filling JSON schema	per-dim 三元组输出格式	高
MCeT [12] atomic decomposition + cross-check	STM 拆 atomic transitions + 可考虑组合 cross-check 与 k-rep	高
MermaidSeqBench [26] 6 维 fine-grained anchored	7 维 vs 6 维对照实验候选	高
CRScore [27] neuro-symbolic grounding	EvidenceDiscipline metric 设计灵感；未来可加静态分析工具作 grounded reference	中
CodeJudge [11] 9-class fault taxonomy	STM 错误分类的 method B 候选	中
UML-Assessment [13] Pearson > 0.76 with TA	Path C human review 自补的 baseline 参考值	高
RESpecBench [28] sound verifier 双轨	与 Subset D protocol-level 数据结合的双轨实验设计	中
Self-Consistency [3] multi-sample	k-rep 协议源头思想（用法不同）	高
Verbalized Confidence [6] just-ask calibration	Calib metric 设计灵感	中
Empirical SE replication [23]	k-rep 协议的方法学背书	高

8.7 我们的位置坐标

	structural	behavioral	free-text	formal spec
class diagram	UML-Assess	--	--	--
sequence diagram	--	MCeT + MermaidSeq	--	--
state machine	--	* THIS WORK *	--	--
code	--	CodeJudge	--	--
review comment	--	--	CRScore	--
NL summary	--	--	G-Eval	--
dialog	--	--	MT-Bench	--
formal spec	--	--	--	RESpecBench

第二维度 **reliability methodology**:

		no rep	sample-vote	sound verifier	k-rep noise
floor + drift					
-----+-----+-----+-----+-----					
-----+					
NLP / generic LLM-as-Judge		主流	SC [3]	--	--
SE-artifact LLM-as-Judge		7 篇	--	--	--
formal spec LLM-as-Judge		--	--	RESpecBench	--
THIS WORK (STM judge)		--	借用思路	--	* THIS
WORK *					

第二个表格的对角线最右下格是真创新（N1）——把 multi-rep noise floor + drift 纪律引入 SE-artifact LLM-as-Judge。

9. 可能的 paper 角度（按野心从小到大）

角度	范围	投稿目标	距离
A Engineering paper	工具 + benchmark	ICSE / ASE Tool track	接近就绪
B Methodology paper（主推）	LLM-as-STM-Judge + noise floor + anchored rubric	EMSE / TSE ; ICLR workshop 备选	数据已有，1-2 周写作
C Empirical study	多配置 trade-off + LOFO 泛化	ICSE / TSE	需再跑 1-2 轮 controlled experiment
D System paper	全套 + Path C	FSE full paper	6 个月+

角度 **B** 收口：noise floor + anchored rubric + STM artifact 三件套是 §6.1 + §6.2 共 14 篇文献全部空缺的方向。

10. 待用户拍板的 4 个判断

10.1 核心 narrative

倾向 **B**（methodology paper），主推方法 = LLM-as-STM-Judge

10.2 目标 venue

倾向 **EMSE + TSE** 双轨

10.3 是否值得自补 Path C human review

倾向 先 **V4** 投出，**Path C** 留 revision / 第二篇

10.4 7 维 rubric keep 7 个还是收缩

倾向 先保 7 维做实验；ablation 之后再决定

11. 暂未深做的事（明确记账）

#	项	状态
1	6 篇 STM review corpus 全文未深读	🕒
2	14 篇 LLM-as-Judge 全文未深读	🕒 DESC.md 仍是 skim 后写
3	未对比 baselines/ 62 篇的 evaluation 章节	🕒
4	未量化 per-subset noise floor 在哪个 metric 上最有信息量	🕒
5	未估算 Path C 实施 cost	🕒
6	未做 rubric ablation（7 维独立贡献）	🕒
7	未做 confidence-formula bug 的方法学化叙事 draft	🕒
8	未追 Awesome-LLMs-as-Judges + Gu24 [8] / Li24 [10] survey 中可能漏的同类工作	🕒

12. §Related Work 段落骨架（可复用到论文里）

§2 Related Work
§2.1 LLM-as-Judge for Free-Text Outputs - G-Eval [Liu23], MT-Bench [Zheng23], Prometheus [Kim24], JudgeLM [Zhu23] - 共同特征: 自由文本 + 单 seed + 隐含 generic rubric - 共同空缺: 未触及 SE artifact、未做 noise floor
§2.2 Aggregation & Calibration - Self-Consistency [Wang23], Verbalized Confidence [Tian23], Constitutional AI [Bai22] - 我们的关系: aggregation 思路借鉴用于 noise floor 而非 vote
§2.3 LLM-as-Judge for SE Artifacts (closest siblings) - CodeJudge [Tong24], CRScore [Naik25] - UML-Assessment [Bouali25], MCeT [Ahmed25], MermaidSeqBench [Shbita25] - RESpecBench [Anon26], SE 2030 vision [He25] - 共同空缺: 未做 noise floor / provider drift; 未覆盖 STM behavioral with guards/temporal
§2.4 STM Quality Evaluation (Pre-LLM) - PSMBench [Lin25], TTool-AI [Apvrille24], llms_emp [Wang25] - Hermes [AlIshtiaq24], RFCNLP [Pacheco22], structure-and-event-driven [Mussbacher26] - 共同空缺: 每篇 schema 不同、跨论文不可比、低规模
§2.5 Bridging the Gap (this work) - LLM-as-STM-Judge: anchored rubric for STM (vs auto-rubric in G-Eval, vs atomic-only in MCeT) - k-rep noise-floor protocol (vs single-seed in §2.1+2.3)

- prompting-only path (vs fine-tune in Prometheus / JudgeLM)
- state machine as first concrete behavioral-model instance with guards / temporal

主要引用句拟稿:

"While LLM-as-Judge has rapidly extended to several SE artifact families — code [Tong24], UML class diagrams [Bouali25], UML sequence diagrams [Ahmed25, Shbita25], and review comments [Naik25] — three methodological gaps remain. First, none adopt a multi-replication noise-floor protocol that distinguishes a genuine improvement from evaluator stochasticity. Second, none discuss provider drift or cache effects, even though our experiments show that cache hits can deflate measured variance by ~50%, hiding the true noise floor. Third, the closest sibling — MCeT [Ahmed25] for UML sequence diagrams — does not generalize to state machines, which add transition guards and temporal constraints. This paper introduces **LLM-as-STM-Judge**, a prompting-only, anchored-rubric, noise-floor-aware judge for state machine artifacts that addresses all three gaps with a 7-dimension anchored rubric, a k-replication noise-floor protocol, and a methodologically explicit treatment of provider drift."

13. 后续讨论建议

1. 先回答 §10 4 个判断
2. 完整通读 14 篇 LLM-as-Judge 论文 (按 [DESC GUIDE.md](#) 修订各 DESC.md)
3. 平行决定 Path C 是否启动招募
4. 把 §3 / §4 内容直接迁到 paper §3 Method / §4 Metrics 草稿
5. 整理 confidence-formula bug 的方法学化叙事 draft 作 paper §3 motivating example

14. References

按引用顺序编号; BibTeX 单条详见 [llm_as_judge_methods_corpus/](#) 与 [state_machine_review_corpus/](#) 各论文目录下 `bibtex.bib`。

14.1 Generic LLM-as-Judge

- [1] **MT-Bench**: Zheng, L., Chiang, W.-L., Sheng, Y., et al. (2023). *Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena*. NeurIPS 2023. <https://arxiv.org/abs/2306.05685>
- [2] **G-Eval**: Liu, Y., Iyer, D., Xu, Y., Wang, S., Xu, R., & Zhu, C. (2023). *G-Eval: NLG Evaluation using GPT-4 with Better Human Alignment*. EMNLP 2023. <https://arxiv.org/abs/2303.16634>
- [3] **Self-Consistency**: Wang, X., Wei, J., Schuurmans, D., et al. (2023). *Self-Consistency Improves Chain of Thought Reasoning in Language Models*. ICLR 2023. <https://arxiv.org/abs/2203.11171>
- [4] **Prometheus**: Kim, S., Shin, J., Cho, Y., et al. (2024). *Prometheus: Inducing Fine-grained Evaluation Capability in Language Models*. ICLR 2024. <https://arxiv.org/abs/2310.08491>
- [5] **Constitutional AI**: Bai, Y., Kadavath, S., Kundu, S., et al. (2022). *Constitutional AI: Harmlessness from AI Feedback*. arXiv:2212.08073. <https://arxiv.org/abs/2212.08073>
- [6] **Verbalized Confidence**: Tian, K., Mitchell, E., Zhou, A., et al. (2023). *Just Ask for Calibration: Strategies for Eliciting Calibrated Confidence Scores from Language Models*. EMNLP 2023. <https://arxiv.org/abs/2305.14975>
- [7] **JudgeLM**: Zhu, L., Wang, X., & Wang, X. (2023). *JudgeLM: Fine-tuned Large Language Models are Scalable Judges*. arXiv:2310.17631. <https://arxiv.org/abs/2310.17631>

- [8] **Survey on LLM-as-a-Judge**: Gu, J., Jiang, X., Shi, Z., et al. (2024). *A Survey on LLM-as-a-Judge*. arXiv:2411.15594. <https://arxiv.org/abs/2411.15594>
- [9] **From Code to Courtroom (SE 2030 vision)**: He, J., Shi, J., Zhuo, T. Y., et al. (2025). *From Code to Courtroom: LLMs as the New Software Judges*. arXiv:2503.02246. <https://arxiv.org/abs/2503.02246>
- [10] **LLMs-as-Judges Comprehensive Survey**: Li, H., Dong, Q., Tang, Z., et al. (2024). *LLMs-as-Judges: A Comprehensive Survey on LLM-based Evaluation Methods*. arXiv:2412.05579. <https://arxiv.org/abs/2412.05579>

14.2 SE-artifact / SE-reliability LLM-as-Judge

- [11] **CodeJudge**: Tong, W., & Zhang, T. (2024). *CodeJudge: Evaluating Code Generation with Large Language Models*. EMNLP 2024. <https://arxiv.org/abs/2410.02184>
- [12] **MCeT**: Ahmed, K., Song, J., Chen, B., Wei, O., & Zheng, B. (2025). *MCeT: Behavioral Model Correctness Evaluation using Large Language Models*. arXiv:2508.00630. <https://arxiv.org/abs/2508.00630>
- [13] **UML-Assessment**: Bouali, N., Gerhold, M., Rehman, T. U., & Ahmed, F. (2025). *Toward Automated UML Diagram Assessment: Comparing LLM-Generated Scores with Teaching Assistants*. CSEDU 2025. <http://www.scitepress.org/Papers/2025/134819/134819.pdf>
- [26] **MermaidSeqBench**: Shbita, B., Ahmed, F., & DeLuca, C. (2025). *MermaidSeqBench: An Evaluation Benchmark for NL-to-Mermaid Sequence Diagram Generation*. NeurIPS 2025 Workshop. <https://arxiv.org/abs/2511.14967>
- [27] **CRScore**: Naik, A., Alenius, M., Fried, D., & Rosé, C. (2025). *CRScore: Grounding Automated Evaluation of Code Review Comments in Code Claims and Smells*. NAACL 2025. <https://arxiv.org/abs/2409.19801>
- [28] **RESpecBench**: Anonymous (2026). *RESpecBench: How Reliable is LLM-as-a-Judge? Rigorous Evaluation of Specification Generation with Automated Verification*. Submitted to ICLR 2026. <https://openreview.net/forum?id=eFwjZIN9eI>

14.3 STM Review Corpus (6 篇)

- [14] **PSMBench**: Lin, Z., et al. (2025). *PSMBench: A Benchmark for Evaluating LLMs on Extracting Protocol State Machines from RFC Specifications*. NeurIPS 2025 Datasets & Benchmarks. <https://openreview.net/forum?id=5HGBeRIHuV>
- [15] **TTool-AI**: Apvrille, L., & Sultan, B. (2024). *TTool-AI: Combining LLMs and Knowledge Bases for SysML Modeling*. MODELSWARD 2024.
- [16] **Ilms_emp**: Wang, Y., Ge, N., et al. (2025). *Empirical Study of LLMs for SysML Behavior Model Generation*. Internetwork 2025 (ACM).
- [17] **Hermes**: Al-Ishtiaq, M., Hussain, S., et al. (2024). *Hermes: Synthesizing Finite State Machines from Cellular Network Specifications*. USENIX Security 2024. <https://arxiv.org/abs/2310.04381>
- [18] **RFCNLP**: Pacheco, M. L., von Hippel, M., Weintraub, B., Goldwasser, D., & Nita-Rotaru, C. (2022). *Automated Attack Synthesis by Extracting FSMs from Protocol Specification Documents*. IEEE S&P 2022. <https://arxiv.org/abs/2202.09470>
- [19] **structure-and-event-driven**: Mussbacher, G., et al. (2026). *Structure- and Event-Driven Frameworks for State Machine Modeling with Large Language Models*. arXiv (cs.SE).

14.4 Foundational / Methodology

[20] **Cohen's Kappa**: Cohen, J. (1960). *A Coefficient of Agreement for Nominal Scales*. Educational and Psychological Measurement, 20(1).

[21] **Hopcroft & Ullman 1979**: Hopcroft, J. E., & Ullman, J. D. (1979). *Introduction to Automata Theory, Languages, and Computation*. Addison-Wesley.

[22] **Alur & Dill Timed Automata**: Alur, R., & Dill, D. L. (1994). *A Theory of Timed Automata*. Theoretical Computer Science, 126(2).

[23] **Empirical SE Replication**: Carver, J. C. (2010). *Towards Reporting Guidelines for Experimental Replications*. RESER. + Juristo, N., & Vegas, S. (2011). *The Role of Non-Exact Replications in Software Engineering Experiments*. EMSE.

[24] **Reproducibility in NLP**: Belz, A., Agarwal, S., Shimorina, A., & Reiter, E. (2021). *A Systematic Review of Reproducibility Research in Natural Language Processing*. EACL 2021.

[25] **Brookhart Rubric**: Brookhart, S. M. (2013). *How to Create and Use Rubrics for Formative Assessment and Grading*. ASCD.

附录 A：关键 commit 与 PR 链接

- PR #6 (W0-W3 archive) : https://github.com/HansBug/research_ideas/pull/6
- PR #8 (project_ex1 拆迁 + V4 验证) : https://github.com/HansBug/research_ideas/pull/8

附录 B：v4 大修动作清单

动作	时间	状态
删去 §5.1 工程贡献叙事	2026-05-08 21:25	✓
§2 / §3 用形式化 + 学术语言重写问题定义 / I/O / 方法	2026-05-08 21:25	✓
§3 加入两张 mermaid pipeline 图 (mmdc 11.14 渲染验证通过)	2026-05-08 21:25	✓
§4 评测指标体系 (每条 metric 给 formal definition + 设计意图 + 可靠性 + 借鉴分析)	2026-05-08 21:25	✓
§4.6 + §4.7 同类工作指标横向对比 + 诚实借鉴	2026-05-08 21:25	✓
§5 数据集结构 (4 subset + split + 实验适用矩阵)	2026-05-08 21:25	✓
§8 重构学术贡献分层 (去掉工程层)	2026-05-08 21:25	✓